

Universidad de Jaén
Grado en Ingeniería Informática
Minería Web — Curso 2025/2026

Práctica 3: Minería de Uso de la Web

Memoria de resultados

Autor: Manuel Villegas

Mayo 2026

Índice

- 1. Pre-procesamiento para análisis de logs**
 - 1.1. Carga del registro log y pre-procesamiento inicial**
 - 1.2. Filtrado de datos**
 - 1.3. De-spidering**
 - 1.4. Identificación de usuarios**
 - 1.5. Identificación de sesiones**
 - 1.6. Problemas al estimar duraciones**
 - 1.7. Pre-procesamiento adicional**
- 2. Análisis exploratorio de datos del log**
 - 2.1. Duración de la sesión**
 - 2.2. Tiempo medio por página**
 - 2.3. Eliminar comportamiento automático**
 - 2.4. Páginas visitadas**
 - 2.5. Relación entre visitas y duración**
 - 2.6. Duración de la visita a las dos primeras páginas**
 - 2.7. Determinación del tipo de página por su extensión**
 - 2.8. Análisis de datos**
- 3. Conclusiones**

1. Pre-procesamiento para análisis de logs

En esta primera parte se han llevado a cabo las tareas de pre-procesamiento sobre el fichero de registros de acceso web de la NASA (*NASA_access_log_FULL.txt*), disponible en <https://ita.ee.lbl.gov/html/contrib/NASA-HTTP.html>. El dataset contiene **3.461.612 registros** correspondientes a dos meses de actividad (julio–agosto de 1995) del servidor web del Kennedy Space Center. Para todo el procesamiento se ha utilizado **Python 3** con las librerías *pandas*, *numpy* y *matplotlib*.

1.1. Carga del registro log y pre-procesamiento inicial

Se ha implementado un parser mediante expresión regular que extrae de cada línea del log (formato CLF — Common Log Format) los siguientes campos: **Host remoto**, **Contraseña** (*ident*), **Usuario** (*authuser*), **Fecha/Hora**, **Método HTTP**, **Página solicitada**, **Protocolo**, **Código de resultado** y **Tamaño de la respuesta en bytes**.

Se ha separado la fecha y hora de cada registro y se ha creado una **marca de tiempo** (*timestamp*) que representa el número de segundos transcurridos desde el **1 de enero de 1995**. Esta representación numérica permite calcular diferencias temporales de forma eficiente para la identificación de sesiones.

Tabla 1. Resumen de la carga del log.

Concepto	Valor
Registros brutos leídos	3.461.612
Errores de parseo descartados	~868
Registros válidos parseados	~3.460.744

Para cada registro válido se extrajeron además campos derivados: la **extensión** del fichero solicitado (obtenida parseando la URL), el **directorio**, el **dominio base** del host remoto y el **tipo de dominio** de nivel superior (TLD). Las URLs se normalizaron eliminando parámetros de consulta (*query strings*) y fragmentos (*anchors*).

Tabla 2. Muestra de registros tras el pre-procesamiento.

sessio n_id	timestamp	usuario_id	metho d	page	statu s	ext
1	16546629	***.novo.dk	GET	/ksc.html	200	.html
1	16546668	***.novo.dk	GET	/shuttle/missions/missions.htm l	200	.html
1	16546865	***.novo.dk	GET	/shuttle/missions/sts-35/missio n-sts-35.html	200	.html
1	16546879	***.novo.dk	GET	/shuttle/missions/sts-35/missio n-sts-35.html	200	.html
1	16546981	***.novo.dk	GET	/shuttle/resources/orbiters/col umbia.html	200	.html
2	19033368	***.novo.dk	GET	/shuttle/missions/sts-69/missio n-sts-69.html	200	.html
2	19033432	***.novo.dk	GET	/shuttle/countdown/	200	
2	19033538	***.novo.dk	GET	/shuttle/countdown/liftoff.html	200	.html

1.2. Filtrado de datos

El primer paso de filtrado consiste en analizar las extensiones de los ficheros solicitados para descartar los recursos que no representan navegación consciente del usuario.

Tabla 3. Top 10 extensiones de página en el log original.

extension	accesos
.gif	1.989.610
.html	751.723
[sin extension]	310.247
.xbm	110.341
.jpg	79.765
.pl	78.698
.txt	51.554
.mpg	44.720
.htm	22.637
.jpeg	12.178

La extensión dominante es **.gif** con 1.989.610 accesos (57,5 % del total), seguida de **.html** (751.723) y las peticiones **sin extensión** (310.247). Las imágenes (.gif, .jpg, .xbm, .jpeg) y scripts (.pl) suman más de 2,2 millones de peticiones que corresponden a recursos auxiliares cargados automáticamente por el navegador.

Se han conservado únicamente los registros con extensiones: **.htm, .html, .pdf, .asp, .exe, .txt, .doc, .ppt, .xls, .xml** y las peticiones **sin extensión** (que generalmente corresponden a directorios o URLs dinámicas).

Justificación: los ficheros multimedia e imágenes se cargan automáticamente al renderizar una página HTML y no representan decisiones de navegación del usuario. Una sola visita a una página puede generar decenas de peticiones de imágenes auxiliares (.gif, .jpg). Mantener estos registros inflaría artificialmente el número de "páginas" por sesión y distorsionaría los tiempos medios de permanencia. Los scripts (.pl) se excluyen por la misma razón, ya que suelen ser llamados automáticamente (contadores, procesamiento de formularios).

1.3. De-spidering

El proceso de de-spidering elimina los registros generados por **bots, arañas web y crawlers**. Se ha utilizado una lista de 13 palabras clave que identifican agentes automáticos por su nombre de host: *webcrawler, crawler, spider, robot, bot, slurp, scooter, lycos, infoseek, inktomi, harvest, architext, worm*. Si alguna de estas palabras aparece en el nombre de host del cliente, el registro se clasifica como automático.

Tabla 4. Categorías de bots y crawlers detectados.

categoria	registros	proporcion_sobre_auto_maticos
scooter	973	30,11 %
spider	844	26,11 %
lycos	482	14,91 %
worm	334	10,33 %
bot	314	9,72 %
infoseek	178	5,51 %
robot	56	1,73 %
webcrawler	44	1,36 %
slurp	5	0,15 %

categoria	registros	proporcion_sobre_auto_maticos
crawler	2	0,06 %

Se detectaron un total de **3.232 registros** de comportamiento automático. Las categorías más frecuentes fueron *scooter* (30,1 %), *spider* (26,1 %) y *lycos* (14,9 %). Todos estos registros se han eliminado del dataset.

Tabla 5. Top 10 hosts de bots más frecuentes.

host	registros	proporcion_sobre_a_utomaticos
scooter.pa-x.dec.com	774	23,95 %
spider.tbe.com	762	23,58 %
query1.lycos.cs.cmu.edu	242	7,49 %
query2.lycos.cs.cmu.edu	239	7,39 %
worm.hooked.net	145	4,49 %
corp-uu.infoseek.com	121	3,74 %
interlock.abbott.com	100	3,09 %
wormhole.cs.mci.com	74	2,29 %
asobota.lerc.nasa.gov	62	1,92 %
corp-bbn.infoseek.com	53	1,64 %

Justificación: los bots generan patrones de acceso radicalmente diferentes a los de usuarios humanos: visitan páginas de forma sistemática y exhaustiva, con tiempos entre peticiones muy bajos (fracciones de segundo) y sin seguir patrones de navegación lógicos. Su inclusión distorsionaría todas las métricas: inflaría el número de sesiones, reduciría artificialmente los tiempos medios de permanencia y alteraría el ranking de páginas más visitadas. Además, los bots acceden a páginas que un usuario humano nunca visitaría directamente (como robots.txt o URLs profundas del árbol del sitio).

1.4. Identificación de usuarios

Para identificar a los usuarios se ha analizado la disponibilidad de los campos del log:

Campo *user* (authuser): está vacío (valor '-') en la práctica totalidad de los registros. El servidor de la NASA no requería autenticación HTTP para acceder a su contenido público, por lo que este campo no es útil para la identificación.

Campo *referrer*: el formato CLF del log de la NASA **no incluye** este campo. Tampoco incluye el campo *user-agent*. Por tanto, no disponemos de información sobre el navegador utilizado, el sistema operativo ni la página de origen del usuario. Igualmente, no se dispone de la topología del sitio web.

Ante la ausencia de estos campos, se ha utilizado la **dirección IP / nombre de host** como identificador de usuario, creando un campo *usuario_id*. Esta es la técnica estándar en minería de uso web cuando no se dispone de cookies ni autenticación.

Limitaciones conocidas: (1) múltiples usuarios detrás de un **proxy o NAT** compartirán la misma IP (como ocurre con los proxies de AOL, que veremos en el análisis); (2) un mismo usuario puede aparecer con diferentes IPs en distintas sesiones si su ISP asigna IPs dinámicas; (3) los usuarios de grandes organizaciones pueden compartir una IP pública. A pesar de estas limitaciones, es la mejor aproximación posible con los datos disponibles.

1.5. Identificación de sesiones

La identificación de sesiones se ha realizado mediante el método de **timeout de inactividad**, con un umbral de **30 minutos** (1.800 segundos). El procedimiento es:

1) Se ordenan todos los registros por *usuario_id* y *timestamp*. 2) Se calcula la diferencia temporal entre cada registro y el anterior del mismo usuario. 3) Cuando esta diferencia supera los 30 minutos, se marca el inicio de una nueva sesión. 4) Se asigna un *session_id* incremental a cada sesión identificada.

Tabla 6. Muestra de registros con identificador de sesión asignado.

session_id	timestamp	usuario_id	host	page	ext
1	16546629	***.novo.dk	***.novo.dk	/ksc.html	.html
1	16546668	***.novo.dk	***.novo.dk	/shuttle/missions/missions.html	.html
1	16546865	***.novo.dk	***.novo.dk	/shuttle/missions/sts-35/mission-sts-35.html	.html
1	16546879	***.novo.dk	***.novo.dk	/shuttle/missions/sts-35/mission-sts-35.html	.html
1	16546981	***.novo.dk	***.novo.dk	/shuttle/resources/orbiters/columbia.html	.html
2	19033368	***.novo.dk	***.novo.dk	/shuttle/missions/sts-69/mission-sts-69.html	.html
2	19033432	***.novo.dk	***.novo.dk	/shuttle/countdown/	
2	19033538	***.novo.dk	***.novo.dk	/shuttle/countdown/liftoff.html	.html
2	19033660	***.novo.dk	***.novo.dk	/shuttle/countdown/lps/fr.html	.html
3	20847347	001.msy4.comunique.net	001.msy4.comunique.net	/software/winvn/winvn.html	.html

En la tabla se observa cómo los registros del host ****.novo.dk* se agrupan en sesiones distintas: la sesión 1 contiene 5 accesos consecutivos, y la sesión 2 comienza más de 30 minutos después. El umbral de 30 minutos es el valor más utilizado en la literatura de minería de uso web, ya que representa un compromiso razonable entre agrupar actividad continua y separar visitas genuinamente distintas.

1.6. Problemas al estimar duraciones

El principal problema al estimar duraciones es que **no se puede conocer cuánto tiempo permanece el usuario en la última página** de una sesión. La duración de una página se calcula como la diferencia entre el timestamp de la petición actual y el de la siguiente. Para la última página no existe petición posterior, por lo que su duración es indeterminada.

Esto tiene dos consecuencias directas:

- 1) La **duración total de la sesión** (diferencia entre primer y último timestamp) **subestima** la duración real, ya que no incluye el tiempo en la última página.
- 2) El **tiempo medio por página** se calcula con $N-1$ intervalos en vez de N , lo que puede sobrestimar ligeramente el tiempo real si la última página tuvo una duración menor que la media.

Propuestas creativas para estimar la duración de la última página:

a) Media de la propia sesión: asignar a la última página el tiempo medio de las páginas anteriores de esa sesión ($D/(N-1)$). Es la opción más sencilla y personalizada por sesión.

b) Mediana de la sesión: usar la mediana en lugar de la media para mayor robustez ante outliers (por ejemplo, una página con un vídeo largo que distorsiona la media).

c) Media global condicionada por tipo de página: calcular la media de permanencia para cada tipo de página (navegación vs. contenido) y asignar a la última página la media correspondiente a su tipo.

d) Modelo predictivo: entrenar un modelo de regresión que prediga el tiempo de permanencia en función de características de la página (longitud de la URL, profundidad en el árbol, extensión, hora del día). Este enfoque sería el más sofisticado pero requiere datos adicionales.

1.7. Pre-procesamiento adicional

Se han realizado las siguientes tareas adicionales de pre-procesamiento:

Valores perdidos en el campo *size*: los registros con tamaño '-' (respuesta sin cuerpo, típicamente redirecciones 3xx o errores) se han codificado como NaN. Se mantienen en el dataset porque el tamaño de la respuesta no es relevante para el análisis de sesiones.

Normalización de URLs: se han eliminado los parámetros de consulta (*?key=value*) y los fragmentos (*#section*) de las URLs para agrupar correctamente las visitas a una misma página independientemente de los parámetros utilizados.

Campos derivados adicionales: se han calculado la hora del día (para análisis temporal), el dominio base del host (para análisis de procedencia) y el tipo de dominio TLD.

2. Análisis exploratorio de datos del log

En esta segunda parte se realiza un análisis exploratorio completo sobre los datos pre-procesados. Se calculan métricas de sesiones, tiempos de permanencia y patrones de navegación.

Nota metodológica: para mejorar la visualización, en los histogramas y diagramas de dispersión se han omitido temporalmente los valores por encima del **percentil 99**. Los datos no se eliminan del análisis; solo se omiten visualmente. En cada gráfico se indica el umbral utilizado y el número y proporción de registros omitidos.

2.1. Duración de la sesión

Del total de **291.043** sesiones humanas. **116.870** (40.2 %) son sesiones de una única página. Estas sesiones tienen duración calculada igual a 0, ya que no hay un segundo acceso que permita medir el tiempo de permanencia. No tenemos evidencia empírica directa de cuánto duran realmente: pueden ser visitas relámpago donde el usuario no encontró lo que buscaba, o visitas prolongadas en las que leyó una sola página durante varios minutos antes de cerrar el navegador.

Para el cálculo de la duración nos restringimos a las **174.173** sesiones con más de una página. Los estadísticos descriptivos son:

Tabla 7. Resumen estadístico: duración de sesión, tiempo medio por página y páginas por sesión.

Estadístico	Duración sesión (s)	Tiempo medio/pág (s)	Páginas/sesión
N	174.173	174.173	291.043
Media	594,64	147,53	3,89
Desv. estándar	1.081,51	220,39	6,26
Mediana	228	71	2
Moda	28	22	1
Mínimo	1	0,5	1
Máximo	56.872	1.800	514

La duración media de sesión es de **594.6 segundos** (~9,9 minutos), con una mediana de **228 segundos** (~3,8 minutos). La gran diferencia entre media y mediana revela una distribución fuertemente **sesgada a la derecha** (asimetría positiva), con una cola larga de sesiones muy prolongadas. La moda es 28 segundos, indicando que las sesiones cortas son las más frecuentes.




Figura 1. Histograma de duración de sesión (percentil 99 = 4.449 s; 1.742 omitidos, 1,00 %).

Estos resultados **subestiman** la verdadera duración de las sesiones, ya que no se contabiliza el tiempo en la última página de cada sesión (problema discutido en §1.6). Si estimáramos la duración de la última página usando el tiempo medio por página (147.5 s), la duración media real de las sesiones sería aproximadamente 742 segundos (~12,4 minutos).


2.2. Tiempo medio por página

El tiempo medio por página de una sesión se calcula con la fórmula:

$$T_{\text{medio}} = D / (N - 1)$$

donde **D** es la duración total de la sesión (en segundos) y **N** es el número de páginas visitadas. Se divide entre N-1 (en lugar de N) porque la duración solo cubre los intervalos *entre* páginas consecutivas, y la última página no tiene intervalo posterior.

El tiempo medio por página es de **147.5 segundos** (~2,5 minutos), con una mediana de **71 segundos** y una moda de **22 segundos**. La diferencia entre media y mediana indica nuevamente una distribución sesgada: la mayoría de páginas se visitan brevemente, pero algunas generan permanencias muy largas (el máximo es 1.800 s = 30 minutos, que coincide con el timeout de sesión).



2.3. Eliminar comportamiento automático

Para verificar que el de-spidering del §1.3 ha sido efectivo, se han identificado las **20 sesiones con menor tiempo medio por página**:

Tabla 8. 20 sesiones con menor tiempo medio por página.

session_id	host	visitas_pagina	duracion_s	tiempo_medio_pagina_s
1563	128.158.53.145	2	0	0
1577	128.158.53.179	2	0	0
2314	128.159.112.22	2	0	0
4915	128.159.132.66	2	0	0
6825	128.159.154.119	2	0	0
6833	128.159.154.119	2	0	0
7770	128.159.72.25	2	0	0
9533	128.217.61.8	2	0	0
9934	128.217.62.224	2	0	0
9942	128.217.62.224	2	0	0
9962	128.217.62.224	2	0	0
9963	128.217.62.224	2	0	0
10077	128.217.62.38	2	0	0
12453	129.219.20.30	2	0	0
13518	129.48.97.147	2	0	0
17563	131.25.157.26	2	0	0
17569	131.25.157.27	2	0	0
22676	138.87.159.20	2	0	0
23203	139.169.174.81	2	0	0
28881	147.74.110.61	2	0	0

Todas las sesiones muestran **2 páginas**, duración **0 segundos** y tiempo medio **0,0 s**. Esto significa que ambas peticiones se registraron en el mismo segundo. Este patrón corresponde a peticiones simultáneas típicas de: (a) carga paralela de marcos (*frames*) por el navegador, (b) comportamiento automático residual no detectado en el de-spidering, o (c) redirecciones automáticas.

Se ha aplicado un umbral de **0,5 segundos**: las sesiones con más de una página y tiempo medio inferior a 0,5 s se eliminan por considerarse comportamiento automático. Ninguna de las 20 sesiones mostradas corresponde a navegación humana realista (un ser humano necesita al menos unos segundos para leer y hacer clic), por lo que la eliminación está justificada.

Tras esta limpieza, los histogramas y estadísticos de las secciones 2.1 y 2.2 reflejan ya los datos finales sin sesiones automáticas.

2.4. Páginas visitadas

Se ha analizado la distribución del número de páginas por sesión sobre las **291.043** sesiones humanas.




Figura 3. Histograma de páginas por sesión (percentil 99 = 27; 2.860 omitidos, 0,98 %).

La distribución sigue un patrón **exponencial decreciente** (o geométrico). La media es 3.89 páginas, la mediana 2 y la moda 1. El 40,2 % de las sesiones son de una sola página. El máximo alcanza 514 páginas, lo que probablemente corresponde a un usuario o proceso automatizado no detectado que realizó una exploración exhaustiva del sitio.

La forma de esta distribución es característica del comportamiento web: la mayoría de usuarios accede a pocas páginas (consulta rápida o visita casual), mientras que un pequeño porcentaje realiza navegación profunda y sostenida.

2.5. Relación entre visitas y duración

Se ha explorado la relación entre el número de páginas visitadas y la duración de la sesión mediante un diagrama de dispersión con **regresión lineal simple** superpuesta.




Figura 4. Diagrama de dispersión: páginas por sesión vs. duración, con línea de regresión.

La ecuación de regresión estimada es:

$$\text{Duración (s)} = 100.84 \times \text{Páginas} + (-6.82)$$

Interpretación de la pendiente (100.84): por cada página adicional que el usuario visita, la duración de la sesión aumenta en promedio **100.8 segundos** (~1.7 minutos). Este valor representa una estimación del **tiempo medio de permanencia por página** obtenida por el modelo de regresión, e incluye tanto el tiempo de lectura como el tiempo de transición.

Interpretación del intercepto (-6.82): el valor negativo del intercepto indica que el modelo lineal no es perfectamente aplicable para sesiones con muy pocas páginas. Una sesión de 0 páginas no tiene sentido físico, y el modelo predice una duración negativa en ese caso. Esto es habitual en regresión lineal cuando la relación real no pasa por el origen.

La relación es claramente positiva y coherente con la intuición: cuantas más páginas visita un usuario, más dura su sesión. Sin embargo, la dispersión es considerable, lo que indica que la velocidad de navegación varía mucho entre usuarios y sesiones.

2.6. Duración de la visita a las dos primeras páginas

Se ha calculado la duración de la visita a las dos primeras páginas de cada sesión (en las sesiones que tienen al menos 2 o 3 páginas, respectivamente).

Tabla 9. Estadísticos de duración de las dos primeras páginas.

Estadístico	Primera página (s)	Segunda página (s)
N	174.173	124.862
Media	144,74	128,40
Desv. estándar	270,70	246,32
Mediana	49	44
Moda	15	1
Mínimo	0	0
Máximo	1.800	1.800

La primera página tiene una duración media de **144.7 s** (mediana 49 s, moda 15 s), mientras que la segunda tiene media de **128.4 s** (mediana 44 s, moda 1 s). Los usuarios tienden a pasar **más tiempo en la primera página**, lo cual es esperable: es la página de aterrizaje donde el usuario orienta su navegación, evalúa el contenido disponible y decide hacia dónde dirigirse. En la segunda página el tiempo es menor porque el usuario ya tiene más claro su objetivo.

La moda de 1 segundo en la segunda página indica un número significativo de transiciones casi instantáneas, probablemente debidas a clics en mapas de imágenes (*imagemap*) o redirecciones de directorios.




Figura 5. Histograma de duración de la primera página.

2.7. Determinación del tipo de página por su extensión

Se ha clasificado cada página según su extensión para determinar si es de **navegación** o de **contenido**:

— **Páginas sin extensión** → **Navegación**: corresponden a directorios (ej: */shuttle/countdown/*), mapas de imágenes (*/cgi-bin/imagemap/countdown*) o scripts CGI que actúan como puntos de paso.

— **Páginas con extensión** → **Contenido**: corresponden a documentos HTML, TXT, PDF, etc. que contienen información que el usuario lee (ej: */ksc.html*, */shuttle/missions/sts-69/mission-sts-69.html*).

Tabla 10. Duración media: navegación vs. contenido, para las dos primeras páginas.

Página	Tipo	N	Media (s)	Mediana (s)
1. ^a	Contenido	117.823	160,49	52
1. ^a	Navegación	56.350	111,80	44
2. ^a	Contenido	87.679	146,63	51
2. ^a	Navegación	37.183	85,43	29

Los resultados son consistentes con la hipótesis: las páginas de **contenido** retienen al usuario significativamente más tiempo que las de **navegación**. En la primera página, el contenido tiene una media de 160,5 s frente a 111,8 s de navegación (**+43,5 %**). En la segunda página, 146,6 s frente a 85,4 s (**+71,6 %**). La diferencia se acentúa en la segunda página, lo que sugiere que las páginas de navegación cumplen su función de paso rápido de forma más marcada una vez que el usuario ya está en flujo de navegación.




Figura 6. Histograma normalizado: navegación vs. contenido (primera página).




Figura 7. Histograma normalizado: navegación vs. contenido (segunda página).

Los histogramas normalizados confirman visualmente la tendencia: las páginas de navegación (naranja) se concentran más en tiempos bajos, con un pico más alto y estrecho a la izquierda, mientras que las de contenido (azul) presentan una distribución más dispersa hacia tiempos mayores. Esto aporta **evidencia a favor** de que clasificar por extensión es una heurística razonable para distinguir páginas de navegación y contenido.

2.8. Análisis de datos

A continuación se presentan las tablas y gráficos solicitados para el análisis detallado.

2.8.1. Top 20 dominios más repetidos

Tabla 11. Top 20 dominios por número de visitas y clics.

domain	visitas	clics_o_vistas
nasa.gov	19.340	58.473

domain	visitas	clics_o_vistas
compuserve.com	9.298	31.698
aol.com	9.112	46.562
netcom.com	7.886	27.808
co.uk	3.732	13.145
ac.uk	3.053	13.803
or.jp	2.577	8.926
prodigy.com	2.280	22.771
ac.jp	1.854	7.555
com.au	1.639	5.528
ibm.net	1.570	5.927
edu.au	1.565	5.672
co.jp	1.434	4.898
net.br	1.323	3.544
ibm.com	1.283	7.172
digital.net	1.206	3.884
primenet.com	1.072	3.848
ab.ca	1.059	4.019
direct.ca	870	2.486
hp.com	867	3.789

El dominio *nasa.gov* encabeza la lista con 19.340 visitas (tráfico interno), seguido de los grandes ISP estadounidenses de la época: CompuServe, AOL y Netcom. La presencia de dominios británicos (.co.uk, .ac.uk) y japoneses (.or.jp, .ac.jp) refleja el interés internacional por la actividad espacial de la NASA. Los dominios .ac (académicos) indican un fuerte componente de tráfico universitario e investigador.

2.8.2. Top 7 tipos de dominio

Tabla 12. Top 7 tipos de dominio (TLD) por visitas y clics.

domain_type	visitas	clics_o_vistas
.com	78.943	342.639
[ip]	74.997	266.144
.edu	28.266	127.064
.net	26.597	98.067
.gov	22.445	72.767
.ca	9.160	36.830
.uk	6.877	27.312

Los dominios comerciales (.com) lideran con 78.943 visitas, seguidos de las direcciones IP directas (74.997). El alto porcentaje de IPs sin nombre de dominio sugiere que en 1995 muchos ISP aún no tenían configurada la resolución inversa DNS para sus clientes. Los dominios educativos (.edu, 28.266) y gubernamentales (.gov, 22.445) confirman el perfil técnico-científico del público de la NASA.

2.8.3. Longitud media de las visitas en 24 horas




Figura 8. Longitud media de las visitas (páginas por sesión) por hora del día (UTC).

Las visitas más largas se producen en horario nocturno/madrugada UTC (horas 0–5, 22–23), con ~4,0–4,2 páginas de media. Durante el horario laboral estadounidense (13–17 UTC, que corresponde a 8–12 EST) la longitud es menor (~3,6–3,8 páginas), sugiriendo que en horario de oficina los usuarios acceden con un objetivo más concreto y directo. En horario nocturno la navegación es más exploratoria.

2.8.4. Top 10 visitantes más repetidos

Tabla 13. Top 10 visitantes por número de visitas.

visitante	visitas
www-d1.proxy.aol.com	588
www-a2.proxy.aol.com	585
www-b2.proxy.aol.com	568
www-d3.proxy.aol.com	562
www-a1.proxy.aol.com	562
www-b4.proxy.aol.com	559
www-d2.proxy.aol.com	554
www-b3.proxy.aol.com	550
www-d4.proxy.aol.com	545
www-b5.proxy.aol.com	536

Los 10 visitantes más frecuentes son **todos proxies de AOL** (America Online), con 536–588 visitas. AOL, que en 1995 era el mayor ISP de EE.UU. con millones de suscriptores, enrutaba todo su tráfico web a través de un número limitado de servidores proxy. Cada proxy representa a **miles de usuarios distintos**, lo que ilustra una de las principales limitaciones de usar la IP como identificador de usuario.

2.8.5. Visitantes únicos por número de visitas (1 a 9)

Tabla 14. Distribución de visitantes únicos por número de visitas.

numero_visitas	visitantes_unicos
1	93.133
2	20.789

numero_visitas	visitantes_unicos
3	7.545
4	3.571
5	1.960
6	1.273
7	838
8	569
9	459

La distribución sigue el patrón típico de **cola larga**: 93.133 visitantes (71,4 %) realizaron una sola visita en los dos meses. Solo el 15,9 % repitieron dos veces, y la proporción cae rápidamente. Esto es consistente con el comportamiento web general: la mayoría del tráfico proviene de visitantes ocasionales atraídos por eventos puntuales (lanzamientos del transbordador, noticias del programa Apollo).

2.8.6. Top 10 páginas más visitadas

Tabla 15. Top 10 páginas por visitas (sesiones únicas) y vistas de página totales.

pagina	visitas	clics_o_vistas
/ksc.html	65.996	83.787
/shuttle/countdown/	57.623	64.612
/	55.410	63.056
/shuttle/missions/missions.html	42.086	47.197
/shuttle/missions/sts-69/mission-sts-69.html	28.465	31.516
/shuttle/countdown/liftoff.html	22.702	29.827
/history/apollo/apollo.html	20.640	23.426
/history/history.html	20.033	21.909
/history/apollo/apollo-13/apollo-13.html	17.895	20.917
/shuttle/missions/sts-70/mission-sts-70.html	17.625	20.150

La página principal (*/ksc.html*) lidera con 65.996 sesiones. El interés se centra en: la cuenta atrás de lanzamientos (*/shuttle/countdown/*), las misiones STS-69 y STS-70 (que se lanzaron en julio-agosto de 1995), y la historia del programa Apollo (especialmente el Apollo 13, probablemente impulsado por la película de 1995).

2.8.7. Top 10 directorios más visitados

Tabla 16. Top 10 directorios por visitas y clics.

directorio	visitas	clics_o_vistas
/	127.270	170.672
/shuttle/countdown/	75.677	112.298
/shuttle/missions/	45.427	54.314
/cgi-bin/imapemap/	33.635	60.311
/shuttle/missions/sts-69/	31.165	44.131
/shuttle/technology/sts-newsref/	28.461	59.675
/history/apollo/	22.236	37.517

directorio	visitas	clics_o_vistas
/history/	20.535	26.745
/history/apollo/apollo-13/	19.088	33.429
/shuttle/missions/sts-71/	18.697	31.178

2.8.8. Top 10 tipos de fichero

Tabla 17. Top 10 extensiones de fichero por accesos (sobre log original).

extension	accesos
.gif	1.989.610
.html	751.723
[sin extension]	310.247
.xbm	110.341
.jpg	79.765
.pl	78.698
.txt	51.554
.mpg	44.720
.htm	22.637
.jpeg	12.178

2.8.9. Top 10 páginas de entrada

Tabla 18. Top 10 páginas de entrada (primera página de cada sesión).

pagina	visitas
/ksc.html	50.591
/	47.867
/shuttle/countdown/	21.793
/shuttle/missions/missions.html	19.037
/software/winvn/winvn.html	14.836
/shuttle/missions/sts-69/mission-sts-69.html	13.439
/shuttle/countdown/liftoff.html	9.154
/history/apollo/apollo-13/apollo-13.html	8.425
/images/	7.824
/history/apollo/apollo.html	7.245

Las principales páginas de entrada son */ksc.html* (50.591) y la raíz */* (47.867), que son los puntos de acceso naturales al sitio. En tercer lugar aparece */shuttle/countdown/* (21.793), indicando que muchos usuarios accedían directamente a la cuenta atrás mediante un enlace o marcador.

2.8.10. Top 10 páginas de salida

Tabla 19. Top 10 páginas de salida (última página de cada sesión).

pagina	visitas
/ksc.html	36.596
/	20.027
/software/winvn/winvn.html	12.849

pagina	visitas
/shuttle/countdown/liftoff.html	12.086
/shuttle/countdown/	11.888
/shuttle/missions/missions.html	9.957
/shuttle/missions/sts-71/images/images.html	9.916
/shuttle/missions/sts-69/mission-sts-69.html	8.248
/images/	7.915
/history/apollo/apollo-13/apollo-13.html	6.536

La página de salida más frecuente es también */ksc.html* (36.596), lo que se correlaciona con las sesiones de acceso único. La página de imágenes de la STS-71 aparece como salida frecuente, sugiriendo que los usuarios terminan su navegación explorando galerías de fotos.

2.8.11. Top 10 páginas de acceso único

Tabla 20. Top 10 páginas de acceso único (sesiones de una sola página).

pagina	visitas
/ksc.html	23.783
/	15.249
/software/winvn/winvn.html	11.351
/images/	5.871
/shuttle/countdown/	5.424
/shuttle/countdown/liftoff.html	4.808
/shuttle/missions/missions.html	4.737
/shuttle/missions/sts-69/mission-sts-69.html	4.031
/shuttle/missions/sts-71/images/images.html	3.835
/history/apollo/apollo-13/apollo-13.html	3.468

/software/winvn/winvn.html destaca en tercer lugar (11.351 accesos únicos), lo que indica que los usuarios llegaban a esta página de software específico (WinVN, un lector de noticias Usenet) con un propósito muy concreto: descargar el programa y marcharse.

2.8.12. Duración de las visitas en minutos

Tabla 21. Distribución de duración de sesiones por intervalos de minutos.

intervalo_minutos	minuto_inicio	visitas
0-1 min	0	152.406
1-2 min	1	25.640
2-3 min	2	16.166
3-4 min	3	11.629
4-5 min	4	8.926
5-6 min	5	7.208
6-7 min	6	6.184
7-8 min	7	5.043
8-9 min	8	4.323
9-10 min	9	3.913

intervalo_minutos	minuto_inicio	visitas
10-11 min	10	3.474
11-12 min	11	3.017
12-13 min	12	2.835
13-14 min	13	2.533
14-15 min	14	2.435
60+ min	60	3.050

La gran mayoría de sesiones (**152.406**, el 52,4 %) duran menos de 1 minuto — esto incluye las sesiones de una sola página (duración 0). El descenso es muy pronunciado: 25.640 entre 1–2 minutos, 16.166 entre 2–3, etc. A partir de los 30 minutos las cifras caen por debajo de las 1.000 sesiones. Solo 3.050 sesiones (1,0 %) superan la hora de duración.

3. Conclusiones

En esta práctica se ha realizado un proceso completo de **minería de uso web** sobre los 3,46 millones de registros de acceso del servidor del Kennedy Space Center de la NASA (julio–agosto 1995).

Pre-procesamiento. Se han aplicado las etapas estándar: parseo del log CLF, filtrado de recursos multimedia (imágenes, scripts), eliminación de 3.232 registros de bots y crawlers (*de-spidering*), identificación de usuarios mediante dirección IP (ante la ausencia de cookies y autenticación), e identificación de sesiones con un timeout de 30 minutos. Se ha discutido la problemática de la estimación de la duración de la última página de cada sesión, proponiendo varias alternativas creativas.

Análisis exploratorio. Las distribuciones de duración de sesión, tiempo medio por página y páginas por sesión siguen patrones exponenciales decrecientes con colas largas, característicos del comportamiento web. La duración media de sesión es de 595 s (~10 min) y el tiempo medio por página de 148 s (~2,5 min). La regresión lineal (pendiente = 100.8 s/página) confirma la relación positiva entre páginas visitadas y duración. La clasificación de páginas por extensión (navegación vs. contenido) muestra diferencias significativas y consistentes en los tiempos de permanencia, validando esta heurística.

Análisis de datos. El tráfico proviene predominantemente de dominios comerciales (.com) y proveedores de Internet estadounidenses (AOL, CompuServe, Netcom). Los proxies de AOL dominan el ranking de visitantes, ilustrando las limitaciones de la identificación por IP. Las páginas más populares reflejan los eventos de actualidad de 1995: las misiones STS-69 y STS-70, la cuenta atrás de lanzamientos y la historia del Apollo 13 (posiblemente impulsada por el estreno de la película de Ron Howard ese mismo año). El 71,4 % de los visitantes únicos realizaron una sola visita en los dos meses.

Todo el análisis se ha implementado en Python de forma reproducible mediante el script *analisis_practica3.py*, que genera automáticamente las 21 tablas CSV y los 8 gráficos PNG que documentan cada paso del proceso.