

Universidad de Jaén
Grado en Ingeniería Informática
Minería Web — Curso 2025/2026

Práctica 3: Minería de Uso de la Web

Memoria de resultados

Autor: Manuel Villegas

Mayo 2026

Índice

- 1. Pre-procesamiento para análisis de logs**
 - 1.1. Carga del registro log y pre-procesamiento inicial**
 - 1.2. Filtrado de datos**
 - 1.3. De-spidering**
 - 1.4. Identificación de usuarios**
 - 1.5. Identificación de sesiones**
 - 1.6. Problemas al estimar duraciones**
 - 1.7. Pre-procesamiento adicional**
- 2. Análisis exploratorio de datos del log**
 - 2.1. Duración de la sesión**
 - 2.2. Tiempo medio por página**
 - 2.3. Eliminar comportamiento automático**
 - 2.4. Páginas visitadas**
 - 2.5. Relación entre visitas y duración**
 - 2.6. Duración de la visita a las dos primeras páginas**
 - 2.7. Determinación del tipo de página por su extensión**
 - 2.8. Análisis de datos**
- 3. Conclusiones**

1. Pre-procesamiento para análisis de logs

En esta primera parte se han realizado las tareas de pre-procesamiento sobre los datos del fichero de registros web de la NASA (fichero *NASA_access_log_FULL.txt*), obtenido del sitio <https://ita.ee.lbl.gov/html/contrib/NASA-HTTP.html>. El fichero contiene 3.461.612 registros de acceso al servidor web del Kennedy Space Center de la NASA durante los meses de julio y agosto de 1995. Se ha utilizado Python con las librerías pandas, numpy y matplotlib para todo el procesamiento.

1.1. Carga del registro log y pre-procesamiento inicial

Se ha implementado un parser basado en expresiones regulares que extrae los campos de cada línea del log en formato CLF (Common Log Format). Cada registro se ha dividido en los siguientes campos: Host remoto, Contraseña, Usuario, Fecha/Hora, Método HTTP, Página solicitada, Protocolo, Código de resultado y Tamaño de la respuesta.

Adicionalmente, se ha separado la fecha y hora de cada registro y se ha creado una marca de tiempo (*timestamp*) que representa el número de segundos transcurridos desde el 1 de enero de 1995 (fecha de referencia). Esta marca de tiempo permite calcular diferencias temporales de forma eficiente para la posterior identificación de sesiones.

Del total de 3.461.612 registros brutos, una pequeña fracción presentó errores de parseo y fue descartada. Para cada registro válido se extrajeron además campos derivados como la extensión del fichero solicitado, el directorio, el dominio base del host y el tipo de dominio de nivel superior (TLD).

Tabla 1. Muestra de registros tras el pre-procesamiento inicial.

host	password	user	method	page	size
***.nov o.dk	-	-	GET	/ksc.html	7067.0
***.nov o.dk	-	-	GET	/shuttle/missions/missions.html	8678.0
***.nov o.dk	-	-	GET	/shuttle/missions/sts-35/mission-st s-35.html	12118. 0
***.nov o.dk	-	-	GET	/shuttle/missions/sts-35/mission-st s-35.html	12118. 0
***.nov o.dk	-	-	GET	/shuttle/resources/orbiters/columbi a.html	6922.0
***.nov o.dk	-	-	GET	/shuttle/missions/sts-69/mission-st s-69.html	11264. 0
***.nov o.dk	-	-	GET	/shuttle/countdown/	4673.0
***.nov o.dk	-	-	GET	/shuttle/countdown/liftoff.html	4665.0

1.2. Filtrado de datos

El primer paso del filtrado consiste en analizar las extensiones de los ficheros solicitados. Se ha construido la tabla con las 10 extensiones más frecuentes en el log original:

Tabla 2. Top 10 extensiones de página en el log original.

extension	accesos
.gif	1989610
.html	751723
[sin extension]	310247
.xbm	110341
.jpg	79765
.pl	78698
.txt	51554
.mpg	44720
.htm	22637
.jpeg	12178

Como se observa, la extensión más frecuente es **.gif** con casi 2 millones de accesos, seguida de **.html** y las peticiones sin extensión. Las imágenes (.gif, .jpg, .xbm, .jpeg) y scripts (.pl) representan recursos auxiliares que se cargan automáticamente y no reflejan navegación real del usuario.

Se han filtrado todas las extensiones excepto: **.htm, .html, .pdf, .asp, .exe, .txt, .doc, .ppt, .xls, .xml** y las peticiones sin extensión (que suelen corresponder a directorios o URLs dinámicas). Este filtrado es necesario porque los ficheros multimedia e imágenes se cargan automáticamente por el navegador al renderizar una página HTML, y no representan acciones conscientes del usuario. Mantener estos registros distorsionaría el análisis de sesiones y patrones de navegación, ya que una sola visita a una página puede generar decenas de peticiones de imágenes auxiliares.

1.3. De-spidering

El proceso de de-spidering elimina los registros generados por bots, arañas web y crawlers, que no representan navegación humana real. Se ha utilizado una lista de palabras clave que suelen aparecer en los nombres de host de estos agentes automáticos: webcrawler, crawler, spider, robot, bot, slurp, scooter, lycos, infoseek, inktomi, harvest, architext y worm.

Tabla 3. Categorías de bots y crawlers detectados.

categoria	registros	proporcion_sobre_automaticos
scooter	973	0.3010519801980198
spider	844	0.26113861386138615
lycos	482	0.14913366336633663
worm	334	0.10334158415841584
bot	314	0.09715346534653466
infoseek	178	0.055074257425742575
robot	56	0.017326732673267328
webcrawler	44	0.013613861386138614
slurp	5	0.001547029702970297
crawler	2	0.0006188118811881188

Se detectaron un total de 3.232 registros de comportamiento automático. Las categorías más frecuentes fueron *scooter* (30,1%), *spider* (26,1%) y *lycos* (14,9%). Los hosts bot más frecuentes fueron *scooter.pa-x.dec.com* (774 registros) y *spider.tbe.com* (762 registros).

Tabla 4. Top 10 hosts de bots más frecuentes.

host	registros	proporcion_sobre_automaticos
scooter.pa-x.dec.com	774	0.23948019801980197
spider.tbe.com	762	0.23576732673267325
query1.lycos.cs.cmu.edu	242	0.07487623762376237
query2.lycos.cs.cmu.edu	239	0.0739480198019802
worm.hooked.net	145	0.04486386138613861
corp-uu.infoseek.com	121	0.03743811881188119
interlock.abbott.com	100	0.03094059405940594
wormhole.cs.mci.com	74	0.022896039603960396
asobota.lerc.nasa.gov	62	0.019183168316831683
corp-bbn.infoseek.com	53	0.01639851485148515

La eliminación de estos registros es fundamental porque los bots generan patrones de acceso muy diferentes a los de usuarios humanos: visitan páginas de forma sistemática, con tiempos de respuesta muy bajos y sin seguir patrones de navegación lógicos. Su inclusión distorsionaría todas las métricas de sesiones, tiempos de permanencia y páginas más visitadas.

1.4. Identificación de usuarios

Para la identificación de usuarios se ha analizado la disponibilidad de los campos del log. El campo *user* (nombre de usuario) está vacío (valor '-') en prácticamente la totalidad de los registros, ya que el servidor de la NASA no requería autenticación para la mayor parte de su contenido. De igual modo, el log CLF de la NASA no incluye campo *referrer* ni *user-agent*, por lo que no se dispone de información sobre el navegador ni sobre la topología de navegación.

Ante la ausencia de estos campos, se ha utilizado la **dirección IP / nombre de host** como identificador de usuario. Se ha creado un campo *usuario_id* que toma el valor del host remoto. Esta aproximación presenta limitaciones conocidas: varios usuarios detrás de un proxy o NAT compartirán la misma IP, y un mismo usuario puede aparecer con diferentes IPs en distintas sesiones. Sin embargo, es la mejor aproximación posible con los datos disponibles y es la técnica estándar en minería de uso web cuando no se dispone de cookies ni autenticación.

1.5. Identificación de sesiones

La identificación de sesiones se ha realizado mediante el método de **timeout de inactividad**, utilizando un umbral de 30 minutos (1.800 segundos). El procedimiento es el siguiente: se ordenan los registros por usuario y marca de tiempo; cuando la diferencia temporal entre dos registros consecutivos del mismo usuario supera los 30 minutos, se considera que ha comenzado una nueva sesión. Se asigna a cada registro un identificador de sesión (*session_id*) incremental.

Tabla 5. Muestra de registros ordenados por sesión y timestamp.

session_id	timestamp	usuario_id	host	page	ext
1	16546629	***.novo.dk	***.novo.dk	/ksc.html	.html
1	16546668	***.novo.dk	***.novo.dk	/shuttle/missions/missions.html	.html
1	16546865	***.novo.dk	***.novo.dk	/shuttle/missions/sts-35/mission-sts-35.html	.html
1	16546879	***.novo.dk	***.novo.dk	/shuttle/missions/sts-35/mission-sts-35.html	.html
1	16546981	***.novo.dk	***.novo.dk	/shuttle/resources/orbiters/columbia.html	.html
2	19033368	***.novo.dk	***.novo.dk	/shuttle/missions/sts-69/mission-sts-69.html	.html
2	19033432	***.novo.dk	***.novo.dk	/shuttle/countdown/	
2	19033538	***.novo.dk	***.novo.dk	/shuttle/countdown/liftoff.html	.html
2	19033660	***.novo.dk	***.novo.dk	/shuttle/countdown/lps/fr.html	.html
3	20847347	001.msy4.comunique.net	001.msy4.comunique.net	/software/winvn/winvn.html	.html

1.6. Problemas al estimar duraciones

El principal problema al estimar la duración de las sesiones y del tiempo en cada página es que **no se puede conocer cuánto tiempo permanece el usuario en la última página** de una sesión. La duración de una página se calcula como la diferencia entre el timestamp de la petición actual y el de la siguiente petición del mismo usuario. Para la última página visitada en una sesión, no existe una petición posterior, por lo que su duración queda indeterminada.

Esto lleva a que la duración total de la sesión (calculada como diferencia entre el primer y último timestamp) **subestima** la verdadera duración, ya que no incluye el tiempo que el usuario pasó en la última página.

Como forma creativa de estimar la duración de la última página, se propone utilizar el **tiempo medio por página** de esa misma sesión como estimación. Es decir, si una sesión tiene N páginas y la duración conocida es D segundos, el tiempo medio por página es $D/(N-1)$, y se puede asignar ese mismo valor a la última página. Otra alternativa sería usar la mediana del tiempo de permanencia en las páginas anteriores de esa sesión, lo que sería más robusto ante outliers. También se podría utilizar la media global del tiempo por página calculada sobre todas las sesiones.

1.7. Pre-procesamiento adicional

Como paso adicional de pre-procesamiento, se han tratado los valores perdidos en el campo *size* (tamaño de la respuesta). Los registros con tamaño '-' se han codificado como NaN y se mantienen en el dataset, ya que el campo de tamaño no es relevante para el análisis de sesiones y navegación. Adicionalmente, se han limpiado las URLs eliminando parámetros de consulta (query strings) y fragmentos (anchors) para normalizar las páginas visitadas.

2. Análisis exploratorio de datos del log

En esta segunda parte se realiza un análisis exploratorio completo sobre los datos pre-procesados, calculando métricas de sesiones, tiempos de permanencia y patrones de navegación. Para mejorar la visualización, en los histogramas y diagramas de dispersión se han omitido temporalmente los valores por encima del percentil 99, indicando en cada gráfico el umbral utilizado y el número de registros omitidos.

2.1. Duración de la sesión

Las sesiones con una única página visitada tienen duración 0, ya que no hay un segundo acceso que permita calcular el tiempo de permanencia. No tenemos evidencia empírica directa de cuánto duran estas sesiones: pueden ser visitas relámpago donde el usuario no encontró lo que buscaba, o visitas prolongadas en las que el usuario leyó una sola página durante varios minutos. Un total de 116.870 sesiones (40,2% del total) corresponden a sesiones de una sola página.

Para el cálculo de la duración, nos restringimos a las sesiones con más de una visita (174.173 sesiones). Los estadísticos descriptivos son:

Tabla 6. Resumen estadístico de duración de sesión, tiempo medio por página y páginas por sesión.

medida	n	media	desviación	mediana	moda	mínimo	máximo
duracion_sesion_s	174173	594.6420570352466	1081.514812908744	228.0	28.0	1.0	56872.0
tiempo_medio_pagina_s	174173	147.53162348579013	220.39146363778318	71.0	22.0	0.5	1800.0
paginas_por_sesion	291043	3.8915899025229947	6.259201558499085	2.0	1.0	1.0	514.0

La duración media de sesión es de 594,6 segundos (aproximadamente 10 minutos), con una mediana de 228 segundos (3,8 minutos), lo que indica una distribución fuertemente sesgada a la derecha. La moda es 28 segundos, indicando que las sesiones cortas son las más frecuentes. El máximo alcanza las 15,8 horas.




Figura 1. Histograma de duración de sesión (percentil 99 = 4.449 s; 1.742 omitidos, 1,00%).

Estos resultados **subestiman** la verdadera duración de las sesiones, ya que no se contabiliza el tiempo en la última página de cada sesión, como se explicó en la sección 1.6.

2.2. Tiempo medio por página

El tiempo medio por página de una sesión se calcula dividiendo la duración total de la sesión entre el número de páginas visitadas menos uno: $T_{\text{medio}} = D / (N - 1)$, donde D es la duración total (en segundos) y N es el número de páginas visitadas. Se resta 1 porque la última página no contribuye a la duración conocida.

El tiempo medio por página es de 147,5 segundos (aproximadamente 2,5 minutos), con una mediana de 71 segundos. La moda es de 22 segundos, lo que sugiere que muchos usuarios navegan rápidamente entre páginas.




Figura 2. Histograma de tiempo medio por página (percentil 99 = 1.220 s; 1.742 omitidos, 1,00%).

2.3. Eliminar comportamiento automático

Para verificar que se han eliminado todos los accesos automáticos, se han identificado las 20 sesiones con menor tiempo medio por página:

Tabla 7. 20 sesiones con menor tiempo medio por página.

session_id	host	visitas_pagina	duracion_s	tiempo_medio_pagina_s
1563	128.158.53.145	2	0	0.0
1577	128.158.53.179	2	0	0.0
2314	128.159.112.22	2	0	0.0
4915	128.159.132.66	2	0	0.0
6825	128.159.154.119	2	0	0.0
6833	128.159.154.119	2	0	0.0
7770	128.159.72.25	2	0	0.0
9533	128.217.61.8	2	0	0.0
9934	128.217.62.224	2	0	0.0
9942	128.217.62.224	2	0	0.0

session_id	host	visitas_pagina	duracion_s	tiempo_medio_pagina_s
9962	128.217.62.224	2	0	0.0
9963	128.217.62.224	2	0	0.0
10077	128.217.62.38	2	0	0.0
12453	129.219.20.30	2	0	0.0
13518	129.48.97.147	2	0	0.0
17563	131.25.157.26	2	0	0.0
17569	131.25.157.27	2	0	0.0
22676	138.87.159.20	2	0	0.0
23203	139.169.174.81	2	0	0.0
28881	147.74.110.61	2	0	0.0

Todas las sesiones de esta tabla tienen un tiempo medio de 0 segundos, con 2 páginas visitadas y duración 0. Esto corresponde a peticiones simultáneas (mismo segundo) de dos URLs, lo que es un patrón típico de comportamiento automático o de la carga paralela de marcos (frames) por parte del navegador.

Se ha aplicado el umbral de **0,5 segundos** de tiempo medio por página para identificar sesiones automáticas: las sesiones con más de una página y tiempo medio inferior a 0,5 s se eliminan por considerarse comportamiento automático. Tras esta limpieza, los histogramas de las secciones 2.1 y 2.2 se han generado ya con los datos finales (sin sesiones automáticas).

2.4. Páginas visitadas

Se ha analizado la distribución del número de páginas visitadas por sesión sobre las 291.043 sesiones humanas finales.




Figura 3. Histograma de páginas por sesión (percentil 99 = 27; 2.860 omitidos, 0,98%).

La distribución sigue un patrón exponencial decreciente. La media es de 3,89 páginas por sesión, la mediana es 2 y la moda es 1, confirmando que la mayoría de sesiones son cortas. El máximo alcanza las 514 páginas, correspondiente probablemente a algún usuario que realizó una exploración exhaustiva del sitio.

2.5. Relación entre visitas y duración

Se ha explorado la relación entre el número de páginas visitadas y la duración de la sesión mediante un diagrama de dispersión con regresión lineal simple superpuesta.




Figura 4. Diagrama de dispersión: páginas vs. duración, con línea de regresión.

La ecuación de regresión estimada es: **Duración = pendiente x Páginas + intercepto**. La pendiente representa el incremento medio de duración (en segundos) por cada página adicional visitada, es decir, es una estimación del tiempo medio que un usuario dedica a cada página. El intercepto (corte con el eje Y) representa la duración base de una sesión incluso antes de la primera transición; en la práctica debería ser cercano a 0 o ligeramente negativo, ya que una sesión con 0 páginas no tiene sentido físico. Un intercepto negativo indica que el modelo lineal no es perfecto para sesiones muy cortas.

En términos comprensibles: por cada página adicional que un usuario visita, la sesión se alarga aproximadamente en el valor de la pendiente. La relación es positiva y coherente con la intuición.

2.6. Duración de la visita a las dos primeras páginas

Tabla 8. Estadísticos de duración de las dos primeras páginas.

medida	n	media	desviacion	mediana	moda	minim o	maximo
primera_pagina_s	17417 3	144.73910 422396122	270.69955 17667325	49.0	15.0	0.0	1800.0
segunda_pagina_s	12486 2	128.40423 027021833	246.31561 000779135	44.0	1.0	0.0	1800.0

La primera página tiene una duración media de 144,7 segundos (mediana 49 s, moda 15 s), mientras que la segunda página tiene una media de 128,4 segundos (mediana 44 s, moda 1 s). Los usuarios tienden a pasar más tiempo en la primera página, lo cual es esperable ya que es la página de aterrizaje donde orientan su navegación. En la segunda página el tiempo es ligeramente menor, sugiriendo que el usuario ya tiene más claro hacia dónde se dirige.




Figura 5. Histograma de duración de la primera página.

2.7. Determinación del tipo de página por su extensión

Se ha clasificado cada página según su extensión: las páginas **sin extensión** se consideran páginas de **navegación** (directorios, imagemaps, scripts CGI), mientras que las páginas **con extensión** (.html, .htm, .txt, etc.) se consideran páginas de **contenido**. Esta clasificación se basa en la observación de que las URLs sin extensión suelen corresponder a directorios (e.g. /shuttle/countdown/) o a scripts de redirección (e.g. /cgi-bin/imagemap/countdown), que actúan como puntos de paso en la navegación.

Tabla 9. Duración media de página: navegación vs. contenido, para las dos primeras páginas.

position	tipo	n	media_s	mediana_s
1	contenido	117823	160.49149147 44999	52.0
1	navegacion	56350	111.80221827 86158	44.0
2	contenido	87679	146.63028775 419428	51.0
2	navegacion	37183	85.426458327 73042	29.0

Los resultados muestran que las páginas de contenido tienen una duración media mayor que las de navegación tanto en la primera como en la segunda página. Para la primera página, el contenido tiene media de 160,5 s frente a 111,8 s de navegación. Para la segunda página, 146,6 s frente a 85,4 s. Esto aporta evidencia a favor de que la clasificación por extensión es razonable: las páginas de contenido retienen más tiempo al usuario porque contienen información que este lee, mientras que las páginas de navegación se usan como puntos de paso rápido.




Figura 6. Histograma normalizado: navegación vs. contenido (primera página).




Figura 7. Histograma normalizado: navegación vs. contenido (segunda página).

Los histogramas normalizados confirman la tendencia: las páginas de navegación se concentran más en tiempos bajos (pico más alto a la izquierda), mientras que las de contenido presentan una distribución más dispersa hacia tiempos mayores.

2.8. Análisis de datos

2.8.1. Top 20 dominios más repetidos

Tabla 10. Top 20 dominios por número de visitas y clics.

domain	visitas	clics_o_vistas
nasa.gov	19340	58473
compuserve.com	9298	31698
aol.com	9112	46562
netcom.com	7886	27808

domain	visitas	clics_o_vistas
co.uk	3732	13145
ac.uk	3053	13803
or.jp	2577	8926
prodigy.com	2280	22771
ac.jp	1854	7555
com.au	1639	5528
ibm.net	1570	5927
edu.au	1565	5672
co.jp	1434	4898
net.br	1323	3544
ibm.com	1283	7172
digital.net	1206	3884
primenet.com	1072	3848
ab.ca	1059	4019
direct.ca	870	2486
hp.com	867	3789

El dominio propio de la NASA (*nasa.gov*) encabeza la lista con 19.340 visitas, seguido de los grandes proveedores de Internet de la época: CompuServe (9.298), AOL (9.112) y Netcom (7.886). La presencia destacada de dominios del Reino Unido (.co.uk, .ac.uk) y Japón (.or.jp, .ac.jp) refleja el interés internacional en la actividad espacial de la NASA.

2.8.2. Top 7 tipos de dominio

Tabla 11. Top 7 tipos de dominio (TLD) por visitas y clics.

domain_type	visitas	clics_o_vistas
.com	78943	342639
[ip]	74997	266144
.edu	28266	127064
.net	26597	98067
.gov	22445	72767
.ca	9160	36830
.uk	6877	27312

Los dominios comerciales (.com) lideran con 78.943 visitas, seguidos de las direcciones IP directas (74.997 visitas) y los dominios educativos (.edu) con 28.266 visitas. El alto número de IPs directas sugiere que muchos usuarios accedían sin resolución DNS configurada.

2.8.3. Longitud media de las visitas en 24 horas




Figura 8. Longitud media de las visitas (páginas) por hora del día.

Se observa que las visitas más largas (en número de páginas) se producen en horario nocturno y de madrugada (horas 0-5 y 22-23), con una media de alrededor de 4,0-4,2 páginas por visita. Durante el horario laboral (8-14) la longitud media es menor (3,6-3,8 páginas), posiblemente porque los usuarios acceden con un objetivo más concreto y directo. Las horas están en UTC.

2.8.4. Top 10 visitantes más repetidos

Tabla 12. Top 10 visitantes por número de visitas.

visitante	visitas
www-d1.proxy.aol.com	588
www-a2.proxy.aol.com	585
www-b2.proxy.aol.com	568
www-d3.proxy.aol.com	562
www-a1.proxy.aol.com	562
www-b4.proxy.aol.com	559
www-d2.proxy.aol.com	554
www-b3.proxy.aol.com	550
www-d4.proxy.aol.com	545
www-b5.proxy.aol.com	536

Los 10 visitantes más frecuentes son todos proxies de AOL (America Online), con entre 536 y 588 visitas cada uno. Esto se debe a que AOL enrutaba todo el tráfico de sus millones de usuarios a través de un número limitado de servidores proxy, por lo que cada proxy representa a miles de usuarios distintos.

2.8.5. Visitantes únicos por número de visitas (1 a 9)

Tabla 13. Visitantes únicos por número de visitas.

numero_visitas	visitantes_unicos
1	93133
2	20789
3	7545

numero_visitas	visitantes_unicos
4	3571
5	1960
6	1273
7	838
8	569
9	459

La inmensa mayoría de visitantes (93.133) realizaron una única visita durante los dos meses. El número decrece rápidamente: 20.789 hicieron 2 visitas, 7.545 hicieron 3, etc. Esto refleja el patrón habitual de tráfico web con una distribución de cola larga.

2.8.6. Top 10 páginas más visitadas

Tabla 14. Top 10 páginas por visitas y vistas de página.

pagina	visitas	clics_o_vistas
/ksc.html	65996	83787
/shuttle/countdown/	57623	64612
/	55410	63056
/shuttle/missions/missions.html	42086	47197
/shuttle/missions/sts-69/mission-sts-69.html	28465	31516
/shuttle/countdown/liftoff.html	22702	29827
/history/apollo/apollo.html	20640	23426
/history/history.html	20033	21909
/history/apollo/apollo-13/apollo-13.html	17895	20917
/shuttle/missions/sts-70/mission-sts-70.html	17625	20150

La página principal del KSC (*/ksc.html*) es la más visitada con 65.996 visitas de sesión distintas, seguida de la página de cuenta atrás del lanzamiento (*/shuttle/countdown/*) y la raíz del sitio. Las misiones STS-69 y STS-70 y la historia del programa Apollo también generan mucho interés.

2.8.7. Top 10 directorios más visitados

Tabla 15. Top 10 directorios por visitas y clics.

directorio	visitas	clics_o_vistas
/	127270	170672
/shuttle/countdown/	75677	112298
/shuttle/missions/	45427	54314
/cgi-bin/imapemap/	33635	60311
/shuttle/missions/sts-69/	31165	44131
/shuttle/technology/sts-newsref/	28461	59675
/history/apollo/	22236	37517
/history/	20535	26745
/history/apollo/apollo-13/	19088	33429
/shuttle/missions/sts-71/	18697	31178

2.8.8. Top 10 tipos de fichero

Tabla 16. Top 10 extensiones de fichero por número de accesos.

extension	accesos
.gif	1989610
.html	751723
[sin extension]	310247
.xbm	110341
.jpg	79765
.pl	78698
.txt	51554
.mpg	44720
.htm	22637
.jpeg	12178

2.8.9. Top 10 páginas de entrada

Tabla 17. Top 10 páginas de entrada por visitas.

pagina	visitas
/ksc.html	50591
/	47867
/shuttle/countdown/	21793
/shuttle/missions/missions.html	19037
/software/winvn/winvn.html	14836
/shuttle/missions/sts-69/mission-sts-69.html	13439
/shuttle/countdown/liftoff.html	9154
/history/apollo/apollo-13/apollo-13.html	8425
/images/	7824
/history/apollo/apollo.html	7245

Las principales páginas de entrada son */ksc.html* (50.591 sesiones) y la raíz */* (47.867 sesiones), lo cual es esperable ya que son los puntos de acceso naturales al sitio.

2.8.10. Top 10 páginas de salida

Tabla 18. Top 10 páginas de salida por visitas.

pagina	visitas
/ksc.html	36596
/	20027
/software/winvn/winvn.html	12849
/shuttle/countdown/liftoff.html	12086
/shuttle/countdown/	11888
/shuttle/missions/missions.html	9957
/shuttle/missions/sts-71/images/images.html	9916
/shuttle/missions/sts-69/mission-sts-69.html	8248
/images/	7915

pagina	visitas
/history/apollo/apollo-13/apollo-13.html	6536

2.8.11. Top 10 páginas de acceso único

Tabla 19. Top 10 páginas de acceso único (sesiones de 1 sola página).

pagina	visitas
/ksc.html	23783
/	15249
/software/winvn/winvn.html	11351
/images/	5871
/shuttle/countdown/	5424
/shuttle/countdown/liftoff.html	4808
/shuttle/missions/missions.html	4737
/shuttle/missions/sts-69/mission-sts-69.html	4031
/shuttle/missions/sts-71/images/images.html	3835
/history/apollo/apollo-13/apollo-13.html	3468

Las páginas de acceso único son aquellas en las que el usuario entra y sale sin visitar ninguna otra. */ksc.html* lidera con 23.783 accesos únicos, seguida de la raíz y */software/winvn/winvn.html* (una página de software que los usuarios probablemente visitaban con un propósito muy específico).

2.8.12. Duración de las visitas en minutos

Tabla 20. Distribución de duración de visitas por intervalos de minutos (muestra).

intervalo_minutos	minuto_inicio	visitas
0-1 min	0	152406
1-2 min	1	25640
2-3 min	2	16166
3-4 min	3	11629
4-5 min	4	8926
5-6 min	5	7208
6-7 min	6	6184
7-8 min	7	5043
8-9 min	8	4323
9-10 min	9	3913
10-11 min	10	3474
11-12 min	11	3017
12-13 min	12	2835
13-14 min	13	2533
14-15 min	14	2435
60+ min	60	3050

La gran mayoría de sesiones (152.406) duran menos de 1 minuto. El número de sesiones decrece rápidamente con la duración: 25.640 sesiones duran entre 1 y 2 minutos, y a partir de los 30 minutos las cifras caen por debajo de las 1.000 sesiones por intervalo. Un total de 3.050 sesiones superan la hora de duración.

3. Conclusiones

En esta práctica se ha realizado un proceso completo de minería de uso web sobre los registros de acceso del servidor del Kennedy Space Center de la NASA, abarcando desde el pre-procesamiento de los datos brutos hasta un análisis exploratorio detallado.

El pre-procesamiento ha seguido las etapas estándar de la minería de uso web: parseo del log, filtrado de recursos multimedia, eliminación de tráfico de bots (de-spidering), identificación de usuarios mediante direcciones IP, e identificación de sesiones con un timeout de 30 minutos. Se ha discutido la problemática inherente a la estimación de duraciones, especialmente la imposibilidad de conocer el tiempo en la última página de cada sesión.

El análisis exploratorio ha revelado patrones interesantes: la distribución de duraciones de sesión y de páginas por sesión sigue distribuciones exponenciales decrecientes con colas largas; el tiempo medio por página es de aproximadamente 2,5 minutos; existe una relación lineal positiva entre el número de páginas y la duración de la sesión; y la clasificación de páginas por extensión (navegación vs. contenido) muestra diferencias significativas en los tiempos de permanencia, validando esta heurística.

El análisis de datos ha mostrado que el tráfico proviene predominantemente de dominios comerciales y de proveedores de Internet estadounidenses de la época, con un interés internacional considerable. Las páginas más populares están relacionadas con las misiones del transbordador espacial y la historia del programa Apollo, reflejando el interés público en la actividad espacial de la NASA en 1995.

Todo el análisis se ha implementado en Python de forma reproducible, generando tablas CSV y gráficos PNG que documentan cada paso del proceso.